

## Vision for federated data networks and remote data science

0:00 hi my name is andrew welcome to this  
0:02 course and welcome to this first lesson  
0:03 on remote data science um in this lesson  
0:06 we're going to walk through just the  
0:07 high level survey of the the core  
0:09 motivations the core components and the  
0:12 main opportunities for you to  
0:14 participate in remote data science and  
0:16 in this first concept we're just going  
0:17 to talk about the motivations so so sort  
0:19 of why remote data science is going to  
0:21 exist and and why it's really going to  
0:23 be the future of of data science and  
0:25 machine learning and statistics and this  
0:27 core motivation is really just that it's  
0:29 going to be a thousand times more data  
0:30 in every scientific field in industry  
0:32 meaning as a result of a handful of new  
0:35 techniques there's going to be a  
0:36 thousand times more data in in most  
0:39 scientific fields in industry as a  
0:41 result of you being able to study data  
0:43 that's distributed across different  
0:44 organizations so so by analogy you know  
0:46 in the same way that the gpus were to  
0:48 compute privacy and technologies are to  
0:51 data right so gpus led to you know  
0:52 orders of magnitude increase in the  
0:54 amount of compute that was available  
0:56 and this led to you know big explosions  
0:57 in ai and innovation and then lots of  
0:59 different sort of applied fields  
1:01 and we're going to see the same thing  
1:02 happen as a result of a similar many  
1:05 order of magnitude increase in the  
1:06 amount of data that's that's available  
1:09 and um the key premise that we have sort  
1:11 of behind this big claim is that our  
1:13 ability to answer important questions is  
1:15 currently very limited because we can't  
1:17 access existing data meaning that you  
1:20 know distributed across organizations  
1:22 around the world are individual data  
1:23 silos that contained it that's valuable  
1:26 right and and  
1:28 you today if you want to to answer an  
1:30 important question you know you say  
1:31 you're a data scientist in a certain  
1:33 country  
1:34 inside of an organization inside of a  
1:35 department of that organization you can  
1:37 only answer questions and data you have  
1:39 a copy of right and and sometimes you  
1:41 know that data might be really big so  
1:43 it's a big web scrape of newswire from  
1:45 the internet but but for problems that  
1:48 are particularly important or problems  
1:50 that are particularly valuable the  
1:52 people who who have access to that data  
1:54 are are less inclined to share

こんにちは、私の名前はアンドリューです。ようこそ。  
もちろん、最初のレッスンへようこそ  
**リモート データ サイエンス**については、このレッスンで  
だけを見ていきましょう  
コアのハイレベル調査  
動機 コアコンポーネントと  
あなたにとっての主な機会  
リモートデータサイエンスに参加し、  
この最初のコンセプトでは、私たちはただ進んでいきます  
動機について話す  
リモートデータサイエンスがなぜそうなるのか  
存在し、そしてなぜそれが実際に存在するのか  
データサイエンスの未来となり、  
機械学習と統計とこれ  
核となるモチベーションはまさにそれです  
データは1000倍になる  
産業のあらゆる科学分野で  
少数の**新しいものの結果として**の意味  
テクニックが登場するだろう  
ほとんどの場合、**数千倍のデータが入力されます**  
産業における科学分野  
データを研究できるようになった結果  
それはさまざまな場所に分散されています  
ご存知のとおり、組織はまあまあです  
GPU と同じように  
コンピューティングのプライバシーとテクノロジーは、  
データは正しいので、GPU でわかります  
桁違いに増加する  
利用可能なコンピューティング量  
そしてこれが大きな爆発につながりました  
AIとイノベーション、そして多くの分野で  
さまざまな種類の応用分野  
そして**私たちは同じものを見ることになるでしょう**  
同様のことが多数起こった結果として起こる  
桁違いの増加  
利用可能なデータの量  
そして、**重要な前提条件**を整理しました  
この大きな主張の背後にあるのは、**私たちの**  
**重要な質問に答える能力は、**  
**現在は非常に限られています。**  
既存のデータにアクセスするということは、  
組織全体に分散していることを知る  
世界中の個人データ  
貴重なものを保管していたサイロ  
そう、そして  
答えたいなら今日あなた  
**重要な質問はあなたが言うことを知っています**  
あなたはある分野のデータサイエンティストです  
国  
組織の内部 組織の内部  
その組織の部門では、次のことができます  
あなたが持っている質問とデータのみに応じてください  
権利のコピー、そして時にはあなたのもの  
データが非常に大きい可能性があることを知っているので、  
それはからのニュースワイヤーの大きなウェブスクレイピングです  
インターネットですが、問題がある場合は  
**特に重要なことや問題があること**  
**特に価値のあるものは、**  
そのデータにアクセスできる人  
共有する傾向が低い

1:56 and then again this is for a wide  
1:57 variety of reasons like like i mentioned  
1:59 you know it could be it could be that  
2:01 it's too expensive right meaning that  
2:03 the act of doing some sort of a data  
2:05 partnership between you and some you  
2:07 know  
2:08 hospital right they just wouldn't bother  
2:10 with with with sort of working with you  
2:13 to facilitate some sort of data sharing  
2:14 agreement maybe your institution is too  
2:16 small or you're an independent  
2:18 researcher and so doing a data sharing  
2:20 agreement with with you know a a bank or  
2:23 a hospital or whatever it just it's just  
2:24 it's just too much trouble for them to  
2:26 be able to work with it could be the if  
2:28 the data is too personal right it could  
2:29 be that they'd be worried that you would  
2:31 misuse that information right it could  
2:32 be legal reasons could be the data can't  
2:34 you know can't go across a  
2:37 national border or or can't leave a  
2:40 particular particular organization you  
2:41 know there's a wide variety of or it  
2:43 could be competitive reasons right so so  
2:45 um data sharing markets are really kind  
2:46 of bifurcated markets because if i if i  
2:49 share a copy of data with you  
2:51 you know sort of if i'm selling data  
2:53 every every  
2:55 customer becomes a competitor for future  
2:58 use of that information you know if i'm  
2:59 an academic and i create this really  
3:01 amazing new valuable academic data set  
3:04 that's going to create a lot of of  
3:05 promising research if i just put that  
3:07 data online you know i just lost the  
3:10 ability to to to have a piece of  
3:13 whatever research or you know be a  
3:14 co-author or whatever it might be of of  
3:18 of of what this information ultimately  
3:20 ends up being used for but or if i'm a  
3:22 commercial business you know i'm a stock  
3:24 trading firm or or or a uh you know i  
3:28 build particular product or service that  
3:30 involves gathering a certain amount of  
3:31 data if i give that data to someone else  
3:33 all of a sudden you know  
3:35 even if they they don't actually use it  
3:37 themselves and they just want to sell it  
3:38 like the the supply of that data will  
3:40 sort of increase as more people copy it  
3:43 and copy it and copy and share with  
3:44 loads of other people the price goes  
3:45 down to zero right so there's loads a  
3:47 huge variety of reasons why data that's  
3:50 distributed among society might not be  
3:52 shareable to you  
3:53 for your data science  
3:55 right  
3:56 and the the core premise the core reason  
3:58 why  
4:00 privacy and technologies and tools to

そしてまたこれは広い範囲のものです  
先ほど述べたようなさまざまな理由  
あなたはそれができるかもしれないことを知っています  
**それは高すぎる**という意味です  
ある種のデータを処理する行為  
あなたと一部のあなたとの間のパートナーシップ  
知る  
病院ですよ、彼らは気にしないでしょう  
あなたと一緒に仕事をするようなものと一緒に  
**ある種のデータ共有を促進するため**  
**おそらくあなたの教育機関も同意するでしょう**  
小さいか独立しているか  
研究者など**データ共有**を行っている  
あなたが知っている銀行との契約、または  
病院でも何でも、ただそれだけです  
彼らにとってそれは面倒すぎる  
それを使って作業できるのは、もししたらそうなるかもしれない  
データが個人的なもののすぎる可能性があります  
彼らはあなたがそうするのを心配しているでしょう  
その**情報を悪用する可能性**がある  
法的な理由によりデータを保存できない可能性があります  
越えられないのはわかってるだろう  
国境を越えられなかったり、  
特定の組織、あなたは  
さまざまな種類があることを知っていますか  
競争上の理由かもしれない  
うーん、**データ共有マーケット**は本当に親切です  
分岐した市場の  
データのコピーをあなたと共有する  
私がデータを販売しているかどうかはわかりますね  
毎回  
**顧客は将来の競争相手になる**  
私なら知っているその情報の使用  
学者であり、私がこれを実際に作成しています  
**驚くべき新しい貴重な学術データセット**  
それはたくさんのを生み出すでしょう  
それだけ言っておきますと、有望な研究です  
オンラインのデータを紛失しただけです  
～の一部を持つ能力  
どんな研究でも、あなたが知っていることでも、  
共著者でも何でも  
**この情報は最終的に何なのか**  
but または if i'm a に使用されることになります  
商業ビジネス、あなたは私が株であることを知っています  
商社、または、または、ああ、知っていますか  
～する特定の製品またはサービスを構築する  
一定量を集めることが含まれます  
そのデータを他の人に渡した場合  
突然、あなたは知っていますか  
実際に使わなくても  
彼らはただそれを売りたいだけなのです  
そのデータの供給が  
コピーする人が増えれば増えるほど  
それを**コピーしてコピーして共有**します  
他にもたくさんの方がいるから値段は上がる  
右にゼロまで下げると、負荷がかかります  
データがそうなる理由は多種多様です  
社会に分配されないかもしれない  
あなたに**共有できる**  
**データサイエンス**のために  
右  
そして核となる前提と核となる理由  
なぜ  
**プライバシーとテクノロジーとツール**

4:02 remote data science are going to  
4:04 increase the amount of data that's  
4:06 available to you by a thousand fold  
4:08 is that  
4:09 it's going to make it possible for you  
4:11 to  
4:11 to do data science to answer questions  
4:15 on data that is distributed across  
4:18 hundreds if not thousands of other  
4:20 organizations that aren't your own  
4:23 right you know you could have access to  
4:25 data that that normally would require  
4:27 you to to partner with a thousand  
4:29 different organizations right a thousand  
4:31 different data sharing agreements a  
4:32 thousand different you know you know  
4:34 phone calls and negotiations and and all  
4:36 the process and rigor and risk  
4:38 management all the things that would  
4:39 normally be involved with accessing a  
4:41 particularly  
4:42 private or or valuable or proprietary or  
4:45 competitive data set  
4:47 is going to become  
4:48 like browsing the internet right it's  
4:50 going to be it's going to that the  
4:51 analogy that i like to to use is sort of  
4:53 as telephones are to the internet right  
4:56 so to like sort of today's kind of data  
4:59 sharing data data sharing agreement  
5:01 based ecosystem are to privacy and  
5:03 technology so like phones are the  
5:04 internet what like you know today's data  
5:06 science tools are to remote data science  
5:09 tools  
5:11 and this this analogy holds really well  
5:13 because you know the internet didn't  
5:15 necessarily increase the amount of  
5:17 information that was available to  
5:19 society you know if you wanted to  
5:21 you know  
5:22 you know the information that now is on  
5:23 wikipedia you could have bought an  
5:24 encyclopedia or gone to the library or  
5:26 whatever if you wanted to buy a plane  
5:28 ticket you could call them up on the  
5:29 phone if you wanted to you know get  
5:30 photos from your relatives you could  
5:31 send it through the mail like like you  
5:33 know  
5:34 the things that we do on the internet  
5:35 people were doing before even if you  
5:36 wanted to to watch a movie you could go  
5:38 to blockbuster or go to movie theater or  
5:40 or just to just purchase purchase a film  
5:42 um but the internet just radically  
5:45 increased the scale and decreased the  
5:47 friction by which this information could  
5:49 be distributed but it can only do it for  
5:51 for data people are happy to share  
5:52 copies of right only data that that just  
5:55 isn't really that valuable or isn't  
5:57 really that that that you know  
5:58 competitive right or isn't it isn't

リモートデータサイエンスは、  
データ量を増やす  
1,000倍で入手可能  
それは？  
それはあなたにとってそれを可能にするでしょう  
に  
**質問に答えるためにデータサイエンスを行う**  
全体に分散されたデータについて  
他にも数千人ではないにしても数百人  
自分のものではない組織  
アクセスできることはご存知ですか  
通常必要となるデータ  
あなたは何千人と提携する必要があります  
さまざまな組織が干渉する  
さまざまなデータ共有契約  
何千もの違う、あなたは知っています、あなたは知っています  
電話や交渉などすべて  
プロセスと厳密さとリスク  
管理するすべてのもの  
通常は、へのアクセスに関与します。  
特に  
私的な、または、貴重な、または独占的な、または  
**競合データセット**  
になる予定です  
インターネットを閲覧するのと同じです  
そうなるだろう それはそうなるだろう  
私が好んで使ったとは、ある種のことで  
電話がインターネットにつながっているのと同じように  
今日のようなデータが好きです  
**データ共有 データ共有契約**  
**ベースのエコシステム**はプライバシーと  
**電話**のようなテクノロジーは、  
**インターネット** 今日のデータをご存知ですか  
**科学ツール**は**リモートデータサイエンス**に**使用されます**  
**ツール**  
この例えは実によく当てはまります  
インターネットがそうではなかったことを知っているからです  
必然的に量が増える  
入手可能な情報  
あなたが**望めばわかる**社会  
ほら  
あなたは今出ている情報を知っていますか  
**ウィキペディア**を買えばよかったかもしれない  
**百科事典**を読んだり、**図書館**に行ったり、  
飛行機を買いたいなら何でも  
**チケット**で電話をかけることができます  
知りたければ電話してください  
親戚からの写真があれば可能です  
あなたと同じように**メール**で送ってください  
知る  
私たちがインターネット上で行うこと  
あなたがいたとしても、人々は以前にそうしていました  
あなたが行ける**映画**を見たいと思っていました  
大ヒット作を観たり、**映画館**に行ったり、  
または単に**フィルム**を購入するだけ  
えー、でも**インターネット**は根本的に  
**規模を拡大し、規模を縮小した**  
この情報もたらず**摩擦**  
配布されますが、それができるのは  
人々が喜んで共有するデータの場合  
正しいデータのみのコピー  
実際にはそれほど価値がないか、そうではありません  
本当にそれはあなたが知っていることです  
**競争権**があるのか、そうでないのか

6:00 really that personal right and and i  
6:02 think that that um  
6:05 the future of of of data science  
6:09 wants to find that data that is  
6:11 particularly valuable i think it also  
6:13 wants people to work with data that's  
6:15 particularly personal because the  
6:16 world's most important problems are  
6:18 problems about people right about about  
6:20 our health about our welfare about our  
6:22 happiness and fairness and bias and like  
6:24 all sorts of really really important  
6:25 things are really person-centric i think  
6:27 um  
6:29 and and what we're going to see you know  
6:30 following along this analogy of of  
6:32 phones of the internet what kind of  
6:34 today's data science tools are to remote  
6:36 data science tools  
6:37 is that the future is is federated data  
6:39 networks right it's like the internet  
6:42 but instead of browsing it with a  
6:43 browser you browse it with a data  
6:45 science tool right and instead of the  
6:47 browser telling the remote server  
6:50 hey send me this data right your data  
6:52 science tool  
6:54 tells a whole host of servers hey  
6:57 **help me answer this question**  
6:59 right help me understand this concept  
7:02 help me you know be able to to to to  
7:05 classify you know cancerous tumors help  
7:08 me be able to understand whether an  
7:10 algorithm is is is bias help me help me  
7:13 to to to to know how how goods and  
7:16 services are moving throughout society  
7:17 you know whatever whatever the question  
7:19 might be  
7:22 this is the future of data science the  
7:24 future of data science is not  
7:26 one-off data sharing agreements with  
7:28 individual you know governments or  
7:30 institutions or whatever it just doesn't  
7:32 scale like who has the time  
7:34 the future is federated data networks  
7:37 powered by privacy handy technologies  
7:40 making it possible for you to answer  
7:42 your data science question using all of  
7:45 the world's relevant information without  
7:47 acquiring a copy of any of it and  
7:49 without needing to to go through sort of  
7:51 heavy  
7:53 you know partnership you know  
7:54 the the today's equivalent of calling  
7:57 people on the phone right  
7:59 the the the that's the future that that  
8:02 this course is really about  
8:04 that's the future that that privacy  
8:05 hands technologies is about that's the  
8:07 future that that federated data network  
8:09 is about and and by by taking this  
8:11 course um so early in its in adoption  
8:14 you're going to be put in a special  
8:15 place to take advantage of this wave

本当にその個人的な権利とそして私  
それはそうだと思う  
データサイエンスの未来  
その**データを見つけない**と思っています  
**特に価値がある**と思います  
人々が次のようなデータを扱ってほしいと考えています。  
特に個人的な理由は、  
世界で最も重要な問題は  
人々に関する問題  
**私たちの健康**について **私たちの福祉**について **私たちのこと**について  
**幸福と公平と偏見と好き**  
あらゆる種類の本当に本当に重要な  
物事は本当に**人間中心**だと思います  
えーっと  
そして、私たちが何を目にするかはあなたも知っているでしょう  
**この類似に従うと、**  
インターネットの電話とはどのようなものですか  
今日の**データ サイエンス ツール**はリモート化されています。  
データサイエンスツール  
未来は**フェデレーテッドデータ**だということです  
ネットワーク、そうです、**インターネットのようなもの**です  
ただし、  
ブラウザでデータを閲覧する  
科学ツールの代わりに  
ブラウザがリモートサーバーに通知する  
ねえ、このデータを送ってください、あなたのデータを正しく送ってください  
科学ツール  
サーバーのホスト全体に「こんにちは」と伝えます  
**この質問に答えるのを手伝ってください**  
この概念を理解するのに役立ちます  
〜〜〜までできることを知っているのを手伝ってください  
癌性腫瘍が役立つことを知っているなら分類する  
かどうかを理解できます  
アルゴリズムはバイアスです 助けて助けて  
へ へ へ どうやって商品や  
サービスは社会全体に広がっています  
あなたは**どんな質問でも何でも知っています**  
そうかもしれない  
これがデータサイエンスの未来です  
データサイエンスの未来はそうではない  
〜との 1 回限りのデータ共有契約  
個人 あなたは政府を知っています  
機関やそれができないもの  
誰が時間があるかというスケール  
未来はフェデレーション データ ネットワークです  
プライバシーハンディテクノロジーを活用  
**あなたが答えられるようにする**  
データ サイエンスに関する質問には、次のすべてを使用します  
世界中の関連情報を  
そのいずれかのコピーを取得し、  
何らかの方法を経る必要がなく、  
重い  
あなたはパートナーシップを知っています、あなたは知っています  
今日の電話に相当するもの  
右側に電話中の人々  
それは、それは、それは未来です  
**このコースは本当に**  
それはその**プライバシー**の未来です  
**ハンズテクノロジー**の魅力はそれです  
フェデレーション データ ネットワークの未来  
これを取ることで、そしてそしてそれによって  
もちろん、導入はかなり早い段階で行われました  
あなたは特別な場所に入れられるでしょう  
この波を活かす場所

8:18 before it happens so i hope that that  
8:20 you kind of get a sense of what the  
8:21 motivation is for these these  
8:23 technologies and um in the the next  
8:25 concept we're going to start walking  
8:27 through uh just uh the first of several  
8:30 example use cases so you can get a a  
8:32 very visceral sense of of  
8:36 the the the  
8:38 the the game-changing nature  
8:40 of of what federated data networks are  
8:43 going to bring so with that i'll see you  
8:45 in the next concept  
英語 (自動生成)

そうなる前にそうなることを願っています  
どういことかなんとかわかりますね  
モチベーションはこれらのためにあります  
テクノロジーと次の話  
**Concept** 僕は歩き始める  
ええと、ちょうどええと、いくつかのうちの最初のものを通して  
使用例を確認できるようにする  
への非常に直感的な感覚  
その  
**ゲームを変える性質**  
フェデレーテッド データ ネットワークとは  
それを持っていくつもりです、それで会いましょう  
**次のコンセプト**では



OpenMined

<https://www.youtube.com/watch?v=ZfjvuLCSPE4>