

L1C10 - Tool 2: Search and example data

0:01 in the last concept we finished with
0:02 remote procedure calls where
0:04 someone who's a data scientist can can
0:06 leverage a very familiar interface to
0:09 control data science tools on remote
0:11 machines thus making it so they don't
0:13 have to centralize all the data in one
0:14 location and avoiding some of the more
0:16 challenging aspects of acquiring a copy
0:18 of a data set but we finished this
0:20 section with with this interesting
0:22 question of how can we actually do good
0:24 data science without looking at the data
0:26 ourselves
0:27 in this concept we're going to talk
0:29 about
0:30 the product experience of
0:33 of privacy and technologies meaning like
0:35 what are the things that we can do to
0:37 make it
0:38 feel like we have a copy of the data
0:39 even if we don't or to try to bridge
0:41 those gaps where there are where the
0:43 limitations and the real theme that
0:44 we're going to see here is that
0:46 that with with tools like search or
0:49 tools like example data
0:51 and then there's other tools that we can
0:52 go into as well we're going to focus on
0:53 these two
0:54 there's this whole legacy of tools for
0:57 working with data that's simply too big
1:00 for you to read all of it and it turns
1:02 out this sort of experience translates
1:04 really nicely into data that's simply
1:06 too sensitive or too distant for you to
1:08 actually see all of it so so in the case
1:10 of of a data set that's too large for
1:12 you to to to find relevant data points
1:15 you might use a search tool to actually
1:17 iterate through millions and millions
1:18 and millions of images looking for you
1:20 know candid examples of one one pattern
1:22 or another or you might look at
1:23 individual sub samples of the data as a
1:26 sort of representative sample of this
1:28 big big big big data that you can't look
1:30 at yourself so it's really the theme
1:31 that we're going after and i hope you
1:32 sort of see that this transfers over
1:34 quite nicely i'm going to walk through a
1:36 couple example interfaces of this being
1:38 the case so let's say we've got an
1:39 interface to remote a remote data
1:41 science portal
1:43 and um you know i've got this this
1:46 client towards this this remote pi grid
1:49 server
1:50 and so i call grid.search right standard
1:54 standard idea and the thing is that i'm

私たちが完成した最後のコンセプトでは
リモートプロシージャコールの場所
データサイエンティストならできる
非常に使い慣れたインターフェイスを活用して、
データサイエンスツールをリモートで**制御**
機械はこうしてそうならないようにするので
すべてのデータを 1 つに集中管理する必要がある
場所を特定し、さらに**いくつかのことを回避する**
コピーを入手する際の困難な側面
データセットの一部ですが、これで完了しました
これは興味深いセクションです
実際にどうすれば良いことができるのかという問題
データを見ないデータサイエンス
私たち自身
このコンセプトで話します
だいたい
の製品体験
プライバシーとテクノロジーの意味
そのために私たちにできることは何でしょうか
成功する
データのコピーを持っているような気がする
たとえそうでなくても、橋渡しをしようとしても
そこにあるギャップは、
限界と本当のテーマ
ここで見てみましょう
検索や
サンプルデータなどのツール
他にもできるツールがあります
にも焦点を当てます
この二つ
ツールのこの遺産全体が存在します
単純に大きすぎるデータを扱う
あなたが**それをすべて読むと**、それが変わります
この種の**経験が翻訳される**
単純にデータにうまく取り込むことができます
あなたには敏感すぎる、または遠すぎる
実際にすべてを見てみましょう
大きすぎるデータセットのうちの
関連するデータポイントを見つけるには
実際に検索ツールを使用するとよいでしょう
何百万も繰り返す
そして何百万もの画像があなたを探しています
一つ一つのパターンの率直な例を知る
または別のもの、またはあなたは見るかもしれません
データの個々のサブサンプルを
この代表的なサンプルのようなもの
大きな大きな大きな大きなビッグデータは見ることはできません
自分自身にそれが本当にテーマです
私たちはそれを追いかけています、そして私はあなたがそれを願っています
これが転送されるのがわかります
とてもうまく、私は通りを歩くつもりです
この**存在のインターフェイス**のいくつかの例
ケースがあるので、
リモートへのインターフェース、リモートデータ
科学ポータル
そして、ええと、私はこれを持っていることを知っています
このリモート PI グリッド**に対するクライアント**
サーバ
それで私は**grid.search**を正しい標準と呼びます
標準的な考え、そして**問題は私がそうである**ということです

1:55 actually searching on the public
1:57 metadata in this case
1:59 to be able to find private data that's
2:01 relevant for me right so in this case i
2:02 might be looking for diabetes data and i
2:04 find that you know there's a few few
2:06 results that were returned to me um you
2:08 know if i look at one of these pointers
2:09 there's sort of certain metadata that
2:11 comes with it right so i can see you
2:13 know some tags i can see shape i can see
2:15 you know some descriptions of how this
2:17 data was collected what the data is
2:18 actually about
2:20 and of course you know attach this data
2:22 can be other public data that that tells
2:24 me even more about this information such
2:26 as such a sample data so i can actually
2:28 look at something and sort of understand
2:30 some of the latent patterns that that
2:32 that might not be obvious from the
2:33 description in terms of how the data set
2:34 works um and so what i this is really
2:37 just kind of like a a small nugget of of
2:40 a broader product experience
2:42 uh problem but with but for which there
2:45 are many many solutions and i think that
2:47 there's there's a longer period of time
2:50 through which the the sort of remote
2:51 data science experience is going to
2:53 continue to iterate but we have lots and
2:54 lots of really good fodder to start with
2:56 simply because the problem of doing data
2:58 science and data that that you're not
2:59 allowed to actually look at in its
3:00 entirety is very similar to the product
3:03 experience of working with data that's
3:05 just too big for you to ever really
3:06 think about looking at in its entirety
3:08 right
3:09 so what tools have we looked at so far
3:11 remote procedure calls where data
3:12 remains in our remote machine that
3:13 solves some really big important
3:15 problems right that does most of the
3:16 heavy lifting of sort of remote data
3:18 science
3:19 second is search and sample data you
3:20 know we can we can feature engineer with
3:22 sample data you know and if we actually
3:24 need to look at some pieces we could we
3:25 could request small snippets from from
3:27 the data owner to actually let us look
3:29 at it or maybe like a synthetic
3:31 generator like a gan or something like
3:32 this can can generate similar data but
3:34 not quite exactly the same data that is
3:37 that is the actual private data at a at
3:39 a remote location um but we still
3:41 haven't solved all the problems so for
3:43 example
3:44 we can still
3:45 **pull data out using this dot get method**
3:48 right what does it actually mean for us

実際に一般公開で検索している
この場合のメタデータ
プライベートデータを見つけることができる
私にとって適切なので、この場合は私は
糖尿病のデータを探しているかもしれないし、
いくつかあることを知っていることがわかります
私に返された結果、ええとあなた
これらのポインタの 1 つを見ればわかる
ある種のメタデータがあります
ちゃんと付属しているので、会えますよ
いくつかのタグを知っています、形が見えます、見えます
あなたはこれがどのように起こるかについていくつかの説明を知っています
データは収集されました データは何ですか
実は約
もちろん、このデータを添付することはご存知でしょう
それが伝える他の公開データである可能性があります
この情報についてさらに詳しく知りたい
このようなサンプルデータなので、実際に
何かを見てなんとなく理解する
潜在的なパターンのいくつかは、
それは、からは明らかではないかもしれませんが
データセットの方法に関する説明
うまくいきます、それで、これは実際には何ですか
の小さな塊のようなもの
より幅広い製品体験
うーん、問題はあるけど、それはそれで
解決策はたくさんありますが、私はそう思います
もっと**長い期間がある**
それを通して一種の**リモコン**が
データサイエンスの経験は、
繰り返しを続けますが、たくさんあります
まずは本当に良い飼料がたくさんある
単純にデータ処理の問題があるからです
科学とデータによると、あなたはそうではない
実際に見ることができません
全体が製品と非常によく似ています
データを扱った経験
あなたには本当に大きすぎる
全体を見ることを考える
右
これまでにどのようなツールを見てきましたか
リモート プロシージャ コールのデータ
リモートマシンに残っているのは、
本当に重要ないくつかを解決します
ほとんどの問題を解決します
リモートデータのような重労働
化学
2 番目は**検索とサンプル データ**です。
フィーチャ エンジニアができることを知っています
あなたが知っているサンプルデータと、実際に
いくつかの作品を見る必要があるので、できますか
から小さなスニペットをリクエストできます
データ所有者に実際に見てもらいましょう
あるいは合成のようなものかもしれません
ガンなどのジェネレーター
これにより同様のデータを生成できますが、
まったく同じデータではありません
それは、**ある時点の実際のプライベートデータ**です
遠い場所、ええと、でも私たちはまだ
すべての問題を解決したわけではないので、
例
まだできます
この dot get メソッドを使用してデータを取り出します
それは私たちにとって実際に何を意味するのでしょうか

3:50 to to
3:52 ask for our results back in a secure way
3:55 like this seems like a really obvious
3:57 bottleneck and if i've got pointers to
3:59 the remote data can i just call dot get
4:01 on those pointers and actually pull the
4:03 data out myself
4:04 the next concept we're going to explore
4:06 a really powerful technology called
4:08 differential privacy which can be used
4:09 to address this problem see you then
英語 (自動生成)

へへ

安全な方法で結果を要求する

これは本当に明らかなことのように思えます

ボトルネックとそのヒントがあるかどうか

リモートデータは **dot get を呼び出す**だけでよいでしょうか

これらの**ポインターに基づいて実際にプル**します

自分でデータを出します

私たちが検討する次のコンセプト

と呼ばれる非常に強力な**テクノロジー**

利用できる**差分プライバシー**

この問題を解決するには、また会いましょう



OpenMined

https://www.youtube.com/watch?v=D9j_WCT25Zg